

UNIDAD N° 1

INTRODUCCIÓN AL ANÁLISIS DE DATOS

Conceptos fundamentales: datos, información y conocimiento.
Historia y evolución del análisis de datos.
Importancia del análisis de datos en contextos tecnológicos.
Primeras consideraciones éticas en el manejo de datos.

UNIDAD N° 1: INTRODUCCIÓN AL ANÁLISIS DE DATOS

Análisis de datos, ingeniería de datos, ciencia de datos, minería de datos, aprendizaje automático o, en inglés, *Data Science*, *Data Mining* y *Machine Learning*. Éstos son algunos términos que surgieron en las últimas décadas, pero que en estos años se están volviendo cada vez más populares y visibles en la comunidad. Las empresas comienzan a solicitar estas profesiones, las instituciones educativas aumentan sus ofertas con carreras destinadas a tales fines y en las redes sociales se observa un aumento enorme de contenido destinado a los datos. Este curso se suma a este movimiento para enseñar todo lo referente a los datos, qué son, cómo se trabajan y qué podemos obtener de ellos.

1. INTRODUCCIÓN

1.1 Breve historia y evolución

Tomar datos para poder comprender el estado de lo observado no es una actividad novedosa. Desde hace siglos (incluso milenios) la humanidad encontró formas diferentes de registrar y tratar datos. Pero, para no irnos tan atrás en el tiempo, veamos algunas historias relevantes que indican cómo obtener y analizar datos resultó ser fundamental para lograr un objetivo.

Para quienes se forman en programación, el análisis de datos resulta especialmente relevante porque muchas aplicaciones actuales no solo almacenan información, sino que también la procesan, la visualizan y la utilizan para generar recomendaciones, detectar errores, mejorar procesos o anticipar comportamientos. Por eso, aprender a pensar con datos complementa las habilidades de programación, bases de datos y desarrollo de software.

1.1.1 Florence Nightingale (1820 – 1910)

En 1854, Gran Bretaña, Francia y Turquía iniciaron contra Rusia lo que se denominó la guerra de Crimea. En noviembre, Florence y un equipo de 38 enfermeras voluntarias, al que entrenó personalmente, acudieron al campamento militar de soldados británicos. Florence notó que el estado de salud en estos campos era devastador. Los soldados heridos recibían tratamientos inadecuados por parte del sobrecargado equipo médico,

los suministros médicos escaseaban, la higiene era pésima, los desagües eran deficientes, la ventilación de aire insuficiente y las infecciones comunes resultaban ser fatales. Durante su primer verano en el campamento, fallecieron diez veces más soldados de enfermedades transmisibles e infecciosas (tifus, fiebre tifoidea, cólera y disentería) que de heridas en el campo de batalla.

Así, seis meses después de la llegada de Florence Nightingale, efectuó la limpieza de los vertederos contaminados, mejoró la ventilación, proporcionó agua potable y frutas, y pidió ayuda al gobierno británico para mejorar el equipamiento sanitario. A partir de esas medidas el índice de mortalidad bajó del 60% al 42% y luego al 2,2%.

Florence tenía conocimientos matemáticos y registró todos estos datos. A su regreso a Londres, comenzó a estudiar estas pruebas a fin de sustentar su posición de que los soldados fallecían a causa de las deplorables condiciones de vida en el hospital y no por la guerra misma. Así, confeccionó y entregó a la Comisión Real para la Salud en el Ejército el diagrama que se visualiza en la siguiente figura:





Diagrama de las causas de la mortalidad del ejército en el Este, por Florence Nightingale.

De esta forma, Nightingale fue considerada una gran estadística y una referente en el uso de gráficos para comunicar evidencia. Su célebre diagrama de áreas polares permitió mostrar con claridad que muchas muertes podían asociarse a condiciones sanitarias deficientes, fortaleciendo la toma de decisiones basada en datos.

1.1.2 John Snow (1813 – 1858)

En 1854 se produjo en Londres el brote de cólera más violento de Inglaterra. Aproximadamente 700 personas fallecieron en el barrio de Soho en menos de una semana, en un área de apenas medio kilómetro de diámetro. John Snow, médico inglés reconocido en el campo de la anestesia y considerado el padre de la epidemiología, creía que el cólera se transmitía a través de fuentes de agua contaminadas y no a través del aire y logró demostrar su punto a través de su ahora famoso mapa. Después del brote de cólera, representó las muertes registradas en un mapa y descubrió que la mayoría de ellas habían ocurrido cerca de una bomba de agua pública. Así es como la investigación de Snow allanó el camino para encontrar la causa del problema mediante la visualización de datos como herramienta para el análisis.

El mapa recogía las defunciones con unas finas líneas de color negro que se iban apilando unas sobre las otras a medida que el número de decesos aumentaba. El resultado fue clarificador: la mayor parte de las muertes se habían producido en las proximidades de Broad Street. De igual manera Snow georreferenció sobre el mapa los pozos de agua, viéndose claramente como una gran cantidad de víctimas se concentraban en torno a la bomba de agua de Broad Street.



Mapa de John Snow. Las rayas son casos de cólera durante la epidemia y los puntos la ubicación de las bombas de agua. [wikipedia2026snow]



Zoom sobre la bomba de agua de Broad Street.

Observá cómo la concentración de marcas alrededor de la bomba de agua permite formular una hipótesis sobre el origen del brote. Este es un ejemplo temprano de cómo una visualización puede ayudar a detectar un patrón que no resulta evidente en una lista de datos.

Snow ya venía trabajando con este tipo de mapas en sus artículos y exposiciones ya que ayudaba a argumentar sus hipótesis. Sin visualizar los datos en un mapa, habría sido difícil darse cuenta de que la mayoría de las muertes por cólera se concentraban alrededor de una sola bomba.

Al año siguiente, en 1855, Snow presentó al comité formado para investigar la epidemia una versión actualizada de su ya por entonces famoso mapa, junto a una línea que delimitaba el área de servicio en torno al pozo de Broad Street. De esa forma pudo reforzar la idea de relacionar el agua contaminada con los casos de infección.

Así es como se comprende la importancia de conseguir datos y analizarlos para saber más sobre lo estudiado y resolver los problemas que se presentan.

Pasando directo al siglo XX, la computación y los sistemas hacen que registrar datos

sea uno de los pilares fundamentales para cualquier organización. Surgen las bases de datos (SQL, OLTP), los Data Warehousing, software de tabulación de datos (Excel), etc. En paralelo, se fue desarrollando lo que se denominó inteligencia artificial que, entre otras aplicaciones, puede ser utilizada para aprender patrones a partir de un conjunto de datos. Así aparece el Aprendizaje Automático (ML, Machine Learning), técnicas de automatización que extraen conocimientos a partir de datos.

1.2 El impulso del análisis de datos

En la actualidad, contamos con una inmensidad de datos. Internet, las redes sociales, la computación en la nube y la gran cantidad de dispositivos conectados hacen que se esté hablando de Big Data y de enormes cantidades de datos sobre los que se puede estudiar cualquier cosa que se les pueda imaginar. A esto se suma el avance de los algoritmos que procesan, estudian y aprenden de los datos, lo que permite comprender con mayor profundidad muchos fenómenos, detectar patrones y fundamentar mejor la toma de decisiones.

Este nuevo escenario hizo que los entornos empresariales y sociales impulsen la necesidad de usar todas estas herramientas y metodologías para la toma de decisiones informadas, la optimización de procesos, la comprensión de comportamientos, la anticipación del futuro y la generación de valor agregado. Estas necesidades aparecieron gracias a la gran disponibilidad de datos y la posibilidad de transformarlos en conocimiento útil, además de contar con la evolución de la tecnología de la información —desde sistemas de procesamiento de archivos hasta bases de datos avanzadas— y el constante progreso del hardware que ofrece computadoras cada vez más potentes y accesibles, así como equipos de recolección y almacenamiento de datos.

Por eso, es importante no caer en la situación de "ricos en datos pero pobres en información", donde la masiva cantidad de datos supera la capacidad de comprensión de una empresa sin herramientas potentes. Esto convierte a los datos en "tumbas de datos" y lleva a que las decisiones se basen en la intuición en lugar de la información valiosa que contienen. Hay que entender que nos encontramos en un mundo y una época donde los datos no pueden ser ignorados; hay que comprender que en ellos se puede conseguir información y conocimiento sumamente valioso. Extraer conocimiento de forma correcta y automatizada es aprovechar un activo que se encuentra latente en

cada registro y que puede hacer la diferencia.

1.3 Una primera advertencia: analizar datos también implica responsabilidad

Trabajar con datos no es una actividad neutral. Los datos pueden representar comportamientos, decisiones, preferencias o características de personas y organizaciones. Por eso, desde el comienzo de la materia es importante recordar que todo análisis debe realizarse con responsabilidad: cuidando la privacidad, evitando interpretaciones apresuradas, reconociendo posibles sesgos y comunicando los resultados con honestidad.