

UNIDAD N° 1

INTRODUCCIÓN AL ANÁLISIS DE DATOS

UNIDAD N° 1: INTRODUCCIÓN AL ANÁLISIS DE DATOS

2. ANÁLISIS DE DATOS

2.1 Definición

El Análisis de Datos es un "proceso que implica examinar, limpiar y transformar datos con el objetivo de obtener información útil, descubrir patrones, identificar tendencias y tomar decisiones informadas", permitiendo comprender el pasado y el presente de cualquier fenómeno, predecir eventos y comportamientos futuros, optimizar procesos y resultados, y descubrir patrones y relaciones ocultas a simple vista. Dentro de esta definición aparecen algunas ideas que nos acompañarán durante todo el cuatrimestre: dato, información, conocimiento, patrones, tendencias y toma de decisiones.

2.2 Dato, información y conocimiento

El análisis de datos permite procesar datos para obtener información y, a partir de ella, construir conocimiento útil para comprender una situación, resolver un problema o tomar decisiones fundamentadas.

Definir qué es un dato puede resultar complejo, porque su significado depende del contexto en el que se lo utilice. En esta materia, entenderemos un dato como un valor, una característica o un hecho asociado al objeto o fenómeno que se está estudiando. Puede tratarse, por ejemplo, de una edad, una fecha, una calificación, una cantidad de ventas, el tiempo de respuesta de una aplicación, el número de errores registrados en un sistema o la categoría de un producto.

Los datos, por sí solos, no siempre tienen un significado claro. Muchas veces aparecen como valores aislados, registros sueltos o elementos almacenados en tablas, archivos o bases de datos. Para que esos datos resulten útiles, es necesario organizarlos, procesarlos, relacionarlos con otros datos e interpretarlos dentro de un contexto.

La información surge justamente cuando los datos son organizados, procesados e interpretados de manera que adquieren significado. A diferencia del dato aislado, la información permite describir una situación, reconocer patrones, comparar resultados o identificar comportamientos relevantes. Por ejemplo, saber que una aplicación registró 500 errores durante una semana ya no es solo un dato aislado: es información que

permite comenzar a evaluar el funcionamiento del sistema.

El conocimiento aparece cuando esa información se interpreta dentro de un contexto y permite comprender mejor una situación, explicar un fenómeno o tomar una decisión fundamentada. Siguiendo el ejemplo anterior, si se observa que los errores aumentaron después de una actualización del sistema y se decide revisar un módulo específico, la información se transforma en conocimiento útil para orientar una acción concreta.

Por eso, el trabajo del analista no consiste simplemente en acumular la mayor cantidad posible de datos. Su tarea es reunir datos pertinentes, confiables y suficientes; organizarlos adecuadamente; analizarlos con criterios válidos; interpretarlos en relación con el problema planteado; y transformarlos en información y conocimiento que puedan apoyar la toma de decisiones.

En síntesis, podemos pensar el proceso de la siguiente manera: los datos son la materia prima, la información es el resultado de organizarlos e interpretarlos, y el conocimiento es la comprensión que permite actuar con mayor fundamento.

3. CICLO DE VIDA DEL ANÁLISIS DE DATOS

Analizar datos implica un gran conjunto de etapas, pasos y actividades que definen el ciclo de vida del análisis de datos. Este ciclo de vida puede encontrarse con otros nombres como Descubrimiento de Conocimiento en Bases de Datos (KDD, Knowledge Discovery from Databases) o Proceso Estándar de Industrias Integradas para la Minería de Datos (CRISP-DM, Cross Industry Standard Process for Data Mining). En definitiva, consiste en una secuencia iterativa e interactiva de etapas o fases. **Iterativa** porque el final de alguna de las fases puede hacer volver a pasos anteriores y porque a menudo son necesarias varias iteraciones para extraer conocimiento de alta calidad; e **interactiva** porque el analista de datos debe ayudar en la preparación de los datos, la validación del conocimiento extraído, etc. El proceso de analizar datos se divide en 6 etapas, como muestra la imagen:

1. Definición del problema
2. Recolección de datos
3. Limpieza y preparación

4. Análisis Exploratorio de datos (EDA)
5. Modelado y evaluación
6. Comunicación y despliegue



En otras bibliografías pueden aparecer más o menos etapas, pero el contenido siempre será el mismo. A continuación, detallaremos cada uno de estos pasos. También, en este curso veremos con más profundidad la limpieza y preparación de datos, el análisis exploratorio y el modelado y su evaluación.

3.1 Definición del problema

Todo análisis comienza con un problema a resolver. Puede ser un inconveniente, una pregunta, una necesidad. Pensemos en posibles problemas o preguntas que pueden surgir en una empresa dedicada a la venta online de un producto en particular (por ejemplo, de cocina):

- ¿Cuáles son las características de los clientes más fieles a la empresa? ¿Se puede predecir si una persona en particular puede ser cliente o no?
- ¿Cuál es la principal fuente de comunicación o marketing de un producto en particular? ¿Si incrementamos la publicidad en una red social, cuántos clientes nuevos puede haber?
- De los clientes que ya tenemos, ¿Cuáles son aquellos que más probablemente dejen de ser clientes nuestros? ¿Por qué?
- ¿Cuáles son las plataformas que más ventas registran? ¿Cuál es la tendencia de ventas? ¿A qué se debe?

Acá solamente nombramos pocos ejemplos de un sin número de posibles preguntas que pueden hacerse. El problema puede ser enfocado en el ámbito de publicidad y marketing, en la optimización de procesos de fabricación o comercialización, en la predicción de la evolución de la empresa, etc. En resumen, todo empieza una vez que se sabe a dónde se quiere llegar.

3.2 Recolección de datos

Una vez definido el problema, se debe conocer cuáles son las fuentes de datos que nos aportará el material con el cual trabajaremos.

- **Bases de datos:** Esta es una de las fuentes más comunes si se trabajan con datos propios de una organización. Por medio de consultas SQL podremos conseguir gran parte de lo requerido.
- **Data Warehouses:** Son repositorios unificados de información de múltiples fuentes, históricos y resumidos. Esta unificación ayuda a la obtención de conjuntos de datos limpios e integrados.
- **Archivos de acceso público en la web:** Existen múltiples plataformas donde publican datos abiertos a la comunidad. Los organismos gubernamentales suelen ser un gran ejemplo de estos casos.
- **Otras fuentes de datos:** También se puede recolectar datos desde fuentes de empresas externas mediante permisos.

3.3 Limpieza y preparación de datos

En esta etapa, se busca garantizar que los datos estén en un estado apto para ser estudiado. Aquí, el esfuerzo debe ser mayor, pues la limpieza y preparación se las consideran pasos críticos. Si un conjunto de datos está mal preparado, es decir se deja sucio, entonces los resultados también serán de mala calidad. Cada acción tomada en esta parte del análisis será clave para que el resultado final sea válido y acertado.

Algunas de las actividades comprendidas en este paso, y que veremos con más detalle en las próximas semanas, son:

- Integración de los datos.
- Selección de variables.
- Detección y tratamiento de valores faltantes (nulos).

- Corrección de errores e inconsistencias.
- Detección de valores atípicos.
- Transformación de datos.

3.4 Análisis Exploratorio de Datos (EDA)

El análisis exploratorio de datos o EDA (Exploratory Data Analysis) es un término acuñado por Tukey. Él quiso alentar a los estadísticos a explorar los datos y formular hipótesis que pudieran conducir a nuevos experimentos. Actualmente, en este paso se intenta:

- Resumir los datos en valores estadísticos univariados y multivariados;
- Aplicar técnicas de visualización para observar los datos y posibles patrones;
- Identificar anomalías o comportamientos atípicos; y
- Plantear hipótesis preliminares que ayuden a la interpretación de los resultados finales.


También se suele detectar problemas de calidad provenientes del paso anterior, ahorrando dolores de cabeza si los datos hubiesen sido procesados en la siguiente etapa. Caso contrario, el EDA permite asegurar la calidad de los datos y los resultados.

3.5 Modelado y evaluación

En esta primera unidad no profundizaremos todavía en los modelos, pero sí es importante reconocer que el modelado forma parte del ciclo de vida del análisis de datos.

Una vez que los datos han sido, limpiados, transformados, examinados y entendidos, el paso siguiente es procesarlos por diferentes algoritmos. Estos algoritmos son métodos matemáticos rigurosos que logran encontrar patrones, tendencias o correlaciones entre variables. Estos se encuadran en lo que se denomina Aprendizaje Automático (o Machine Learning) y se clasifican en dos categorías:

- **Aprendizaje supervisado:** trata de inferir una función o relación a partir de datos de entrenamiento etiquetados para luego usar esta función sobre nuevos datos. El objetivo es predecir el valor de las variables de salida a partir de un conjunto de variables de entrada.




- **Aprendizaje No supervisado:** descubre patrones ocultos del conjunto de datos. Aquí no hay variables de salida, simplemente se intenta encontrar patrones y relaciones en los datos.



Los modelos pueden producir resultados útiles, pero su calidad depende de los datos utilizados, de la técnica elegida, de los supuestos del método y de una evaluación adecuada. De todas maneras, deben ser validados correctamente para asegurarse de que no haya habido fallas ni inconvenientes en los pasos previos o incluso en la generación de los modelos. Por esto se debe realizar la evaluación. Más cerca del final de la materia estudiaremos cómo modelar y evaluar con dos métodos ampliamente utilizados: regresión lineal y árbol de decisión.

3.6 Comunicación y despliegue de resultados

Una vez completado el análisis de los datos, se debe realizar el informe final para comunicar el nuevo conocimiento descubierto a los interesados del proyecto. En esta etapa se confeccionan informes, gráficos, dashboards para transmitir información relevante para quienes deban tomar decisiones a futuro. El llamado storytelling es una herramienta que logra maximizar la eficiencia y eficacia de la comunicación. En el caso donde se generaron modelos supervisados pueden comenzar a usarse sobre nuevos datos para predecir las variables objetivos. Cabe aclarar que, a pesar de lograr los resultados esperados, si se mantienen en el mediano y largo plazo deberán estudiarse nuevamente para validar que los patrones hallados siguen siendo válidos o si fueron cambiando con el tiempo.



Esta imagen presenta una forma resumida y alternativa de representar el trabajo con datos. Aunque no usa exactamente las mismas etapas del ciclo desarrollado en este apunte, permite reconocer una idea común: recolectar, preparar, visualizar, analizar y comunicar.

4. IMPORTANCIA DEL ANALISTA DE DATOS

La importancia del análisis de datos radica en su capacidad para potenciar estrategias en todos los niveles de una organización:

- **Mejora de la Toma de Decisiones:** Permite basar las decisiones en hechos y evidencia, reduciendo la incertidumbre y el riesgo.
- **Optimización de Operaciones:** Identifica cuellos de botella, predice fallas de equipos, optimiza rutas logísticas y mejora la eficiencia general.
- **Personalización y Experiencia del Cliente:** Permite comprender las preferencias individuales de los clientes para ofrecer productos, servicios y comunicaciones personalizadas, mejorando la satisfacción y la lealtad.
- **Detección de Fraudes y Riesgos:** Identifica patrones anómalos que pueden

indicar actividades fraudulentas o riesgos financieros.

- **Innovación y Desarrollo de Productos:** Facilita la identificación de nuevas oportunidades de mercado, la creación de productos más inteligentes y la adaptación a las demandas cambiantes de los consumidores.
- **Eficiencia en la Investigación:** En el ámbito científico y de ingeniería, acelera el descubrimiento de nuevos conocimientos al permitir el procesamiento y la interpretación de grandes volúmenes de datos experimentales o de simulación.
- **Ventaja Competitiva:** Las organizaciones que utilizan eficazmente el análisis de datos pueden superar a sus competidores al ser más ágiles, eficientes y orientadas al cliente.

En esta primera aproximación vimos que el análisis de datos no se reduce al uso de herramientas informáticas ni a la aplicación de algoritmos. Analizar datos implica formular buenas preguntas, comprender el contexto, transformar registros en información significativa y comunicar hallazgos que puedan orientar decisiones. En las próximas semanas profundizaremos en cada etapa de este proceso y comenzaremos a trabajar con herramientas concretas para explorar, limpiar, visualizar e interpretar datos.