

UNIDAD N° 2

PREPARACIÓN DE DATOS

Conceptos fundamentales: datos, información y conocimiento.
Historia y evolución del análisis de datos.
Ciclo de vida del análisis de datos: definición, recopilación, limpieza, EDA, modelado, comunicación

UNIDAD N° 2.1: RECONOCIMIENTO Y LIMPIEZA DE DATOS

1. INTRODUCCIÓN

En el análisis de datos, existe una premisa fundamental conocida como **"Garbage In, Garbage Out"** (Si entra basura, sale basura). Podemos aplicar el algoritmo de Inteligencia Artificial más sofisticado del mundo, pero si los datos de entrada son erróneos, incompletos o inconsistentes, los resultados no serán fiables ni útiles para la toma de decisiones.

La **Preparación de Datos** es la etapa del ciclo de vida donde transformamos datos "crudos" en datos de alta calidad.

La preparación de datos no es un paso aislado, sino un conjunto de procesos críticos que garantizan que la información sea apta para el análisis. Antes de comenzar a modelar o visualizar, debemos asegurar la integridad de la fuente y validar que todo el contenido a estudiar represente lo mejor posible a la realidad que se quiere modelar.

1.1 ¿Qué es la Calidad de Datos?

La calidad de datos indica qué tan buenos son para sacar conclusiones de ellos. Refieren al estado de los datos y su idoneidad para un propósito específico. Se mide a través de dimensiones concretas que debemos validar:

- **Compleitud:** ¿Faltan datos en registros o columnas importantes?
- **Validez:** ¿Los datos respetan el formato y tipo esperado? ¿Respetan las reglas de negocio previamente definidas?
- **Consistencia:** ¿La información es coherente entre diferentes tablas o fuentes?
- **Unicidad:** ¿Existen registros duplicados que puedan sesgar las estadísticas?
- **Precisión:** ¿Los datos reflejan la realidad sin errores de carga o medición?

1.1 ¿Cómo se mejora la calidad de los datos?

Existen diversas formas de aumentar la calidad de los datos. Actualmente, se siguen estudiando diversas técnicas que permitan la mejora y corrección sin generar modificaciones excesivas sobre los datos. Durante esta unidad, abordaremos tres

grandes ejes globales que componen la preparación junto a técnicas que, a pesar de ser básicas, son indispensables:

- **Reconocimiento de datos:** Aquí identificamos la estructura del dataset, su formato, las variables que posee, el tipo de cada una de ellas, la cantidad de filas, etcétera.
- **Selección de datos:** Decidimos qué datos conservar (o qué datos sacar del estudio).
- **Limpieza de datos:** Resolvemos de conflictos, errores, nulos y valores atípicos.
- **Transformación de datos:** Modificaremos algunas de las variables para mejorar el estudio y hacernos más fácil los siguientes procesos del ciclo de vida del análisis de datos.

2. Integración de Datos. El paso previo

Después de recibir una pregunta o un objetivo a alcanzar que conlleve el análisis de datos, se debe primero encontrar las fuentes de estos. Rara vez los datos provienen de una única fuente y suelen llegar desde diversos lugares y formatos. En general provienen de bases de datos propias de la organización o empresa donde se trabaja. Pero también pueden venir de fuentes públicas o privadas, APIs, sensores, encuestas, etc. Además, se debe considerar todos los formatos con los que pueden llegar: csv, tsv, Excel, xml, html, entre otros.

En definitiva, la Integración es el proceso de unificar datos de distintos orígenes en un repositorio común. Durante este proceso surgen desafíos comunes que requieren atención detallada:

- **Definición de tipos:** Una fuente puede traer la fecha como texto ("2024-05-01") y otra como un número serial de Excel (45413). Aquí se debe elegir el formato adecuado para el análisis y hacer que todos contengan este tipo de variable.
- **Unificación de formatos:** "M", "Masculino" y "1" pueden representar lo mismo en distintas fuentes. Es importante asignar los mismos conjuntos de valores para que el algoritmo evite tratar a estos sujetos como categorías diferentes.

- **Identificación y Descomposición:** A veces, una sola columna contiene múltiples datos que deben ser separados para ser útiles. Pongamos como ejemplo una clave de identificación de una póliza de seguros que contenga 1 letra, un número de 8 cifras y 1 dígito al final (V-25342135-1). En este supuesto caso podríamos descomponer la clave en 3 columnas distintas:
 - V: Tipo de vehículo.
 - 25342135: ID del cliente.
 - 1: Número de renovación de la póliza.

De esta forma, los datos serán más fáciles de entender para nosotros y los algoritmos de modelado.

3. Limpieza de datos

3.1 Selección de Variables

Una vez que se tengan todos los datos requeridos para continuar con el análisis, debemos decidir con cuáles columnas vamos a trabajar. No todos los datos recolectados son útiles y, a veces, "más datos" significa "más ruido".

Variables Redundantes: Si el dataset tiene "Fecha de Nacimiento" y "Edad", la información está duplicada. Se deberá quitar para no generar problemas de multicolinealidad en modelos avanzados.

Variables de Baja Varianza: Si la gran mayoría (por ejemplo, el 99.9%) de los valores de una columna es la misma, entonces esa variable no ayuda a discriminar ni a encontrar patrones entre los datos. Esta también será eliminada del estudio.

Identificadores (IDs): Columnas como Nombres, DNIs o números de trámite no aportan información estadística generalizable, ya que son únicos por registro.

3.2 Tratamiento de Valores Faltantes (Nulls)

Los valores faltantes o nulos (NaN en Python, NA en R) son uno de los problemas más frecuentes. Su presencia puede romper los cálculos matemáticos o sesgar los promedios.

3.2.1 Tipos de valores faltantes

Es fundamental entender por qué falta el dato para decidir cómo actuar:

- **MCAR (Missing Completely at Random):** El dato falta por puro azar (ej. un sensor que falló un segundo por un bache de tensión). No hay relación con otras variables.
- **MAR (Missing at Random):** La falta de datos depende de otra variable observada (ej. es más probable que los hombres no contesten una encuesta sobre cosmética).
- **MNAR (Missing Not at Random):** La falta de datos depende del valor del dato mismo (ej. personas con salarios muy altos que prefieren no declararlos en una encuesta de ingresos).

3.2.2 Estrategias de resolución

Según el impacto y el tipo de dato, podemos tomar las siguientes acciones:

- **Ignorar:** No realizar ninguna acción y dejar el nulo. Algunos análisis pueden trabajar sobre variables que posean valores faltantes. Aun así, trataremos de no dejarlos y aplicar alguna otra metodología.
- **Eliminar Columna:** Si la columna tiene una tasa de nulos muy alta (ej. >70%) y no es crítica, se descarta. Esta es una estrategia muy invasiva, por lo que utilizarla con cuidado y en casos específicos.
- **Filtrar Fila:** Esta suele ser una de las formas más comunes de resolver los nulos. Si el registro contiene uno o varios valores nulos en los campos a analizar, entonces este registro se elimina completamente. Esto sirve únicamente si este filtrado no afecta demasiado el conjunto de datos. Si este filtrado no supera un valor aproximado del 10%, entonces no habría muchos problemas; caso contrario, habrá que buscar otra forma de resolverlos.
- **Imputar (Reemplazar valor):** Se le puede asignar un valor estimado que sea coherente. Un camino frecuente es reemplazar los valores nulos por la media o la mediana de una variable cuantitativa (según si existen o no casos atípicos). Si estamos trabajando sobre variables cualitativas, se puede usar la

moda. También existen otras formas más eficaces de imputación, como el uso de modelos algoritmos (como KNN), para predecir el valor faltante basándose en otros registros.

- **Segmentar:** Se puede crear una o varias variables para incluir los valores nulos como una nueva clasificación. Esta técnica la veremos en detalle la semana que viene.
- **Esperar:** En procesos de captura en tiempo real, una solución es aguardar a que el dato sea corregido por la fuente o por especialistas en el tema.

3.3 Tratamiento de Valores Erróneos

Puede suceder que exista algún valor observado que no cuadra con el significado de la variable. Tome los siguientes ejemplos:

- Código de patente = SA251CL (no existe patentes que comiencen con S)
- Edad = 236 años (es imposible que una persona haya llegado a esa edad)
- Sexo = K (si pensamos que las posibilidades son F y M, entonces K es un error)
- Cantidad de hijos = 2,2 (esta variable solo acepta valores discretos).

Estos y muchos más casos pueden presentarse al momento de estudiar un dataset. En todos los casos, la solución es eliminar este valor erróneo para dejarlo nulo y resolverlo como cualquier valor faltante.

3.4 Detección de valores atípicos (Outliers)

3.4.1 ¿Cómo detectarlos?

- **Regla de los Tres Sigmas (Z-Score):** Se basa en la desviación estándar. Cualquier dato que se aleje más de 3 desviaciones de la media es sospechoso.
- **Rango Intercuartílico (IQR):** Método usado en Boxplots. Se define un límite superior e inferior basado en los cuartiles Q1 y Q3.

3.4.2 ¿Qué hacer con ellos?

- Si el valor atípico se debe a un error obvio (Edad = 236 años), entonces se lo debe tratar como un valor faltante, como hemos visto anteriormente.
- Si, en cambios, decimos que es un valor válido o correcto, entonces se lo debe mantener intacto aunque considerando la existencia de estos valores atípicos, ya que pueden distorsionar las métricas que saquemos al analizar el conjunto.

4. BUENAS PRÁCTICAS

Para que tu proceso de limpieza sea profesional, ético y reproducible, sigue estas reglas de oro:

- Documentar cada cambio (Bitácora de limpieza): Cada decisión (ej: "Se eliminó el 5% de los registros por nulos en la columna Sueldo") debe quedar registrada en el notebook o en un informe de curación. Esto garantiza la transparencia del análisis.
- Mantener la inmutabilidad del dato original: Nunca trabajes sobre el archivo fuente directamente. Lee el archivo y crea una copia de trabajo (ej: `df_limpio = df.copy()`). Si algo sale mal, siempre puedes volver a empezar.
- Visualizar antes y después: La mejor forma de validar una limpieza es comparar gráficamente. Un histograma antes de tratar outliers comparado con uno posterior te confirmará si la distribución ahora es más representativa de la realidad.
- Chequeo de Consistencia Lógica: Realizar pruebas de sentido común. Si la fecha de fallecimiento es anterior a la fecha de nacimiento, hay un error que la limpieza automatizada podría no detectar.
- Auditabilidad: El código debe ser claro y seguir un orden lógico. Alguien ajeno al proyecto debería poder ejecutar tu proceso de limpieza y llegar al mismo dataset resultante.