

UNIDAD N° 3

VISUALIZACIÓN DE DATOS

Marcas visuales y elementos preatentivos.
Tipos de gráficos y diagramas.
Visualización de datos como forma de comunicar.

UNIDAD N° 3: CONCEPTOS BÁSICOS PARA LA VISUALIZACIÓN DE DATOS

1. INTRODUCCIÓN

Durante el ciclo del análisis de datos, principalmente en el proceso de limpieza y preparación, suele ser útil el uso de gráficos, ya que permiten ver el comportamiento de un gran conjunto de datos en un solo vistazo. Así se logra detectar mediante la visión tendencias, valores atípicos o agrupamientos. Existe un ejemplo muy divulgado que se denomina el Cuarteto de Anscombe que demuestra fácilmente la importancia de los gráficos por sobre los analíticos.

1.1 Cuarteto de Anscombe

Tomemos los siguientes 4 conjuntos de datos:

	DATASET 1		DATASET 2		DATASET 3		DATASET 4	
	x	y	x	y	x	y	x	y
0	10	8.04	10	9.14	10	7.46	8	6.58
1	8	6.95	8	8.14	8	6.77	8	5.76
2	13	7.58	13	8.74	13	12.74	8	7.71
3	9	8.81	9	8.77	9	7.11	8	8.84
4	11	8.33	11	9.26	11	7.81	8	8.47
5	14	9.96	14	8.10	14	8.84	8	7.04
6	6	7.24	6	6.13	6	6.08	8	5.25
7	4	4.26	4	3.10	4	5.39	19	12.50
8	12	10.84	12	9.13	12	8.15	8	5.56
9	7	4.82	7	7.26	7	6.42	8	7.91
10	5	5.80	5	4.74	5	5.73	8	6.89


A primera vista no parece nada extraño. Ahora realicemos un análisis estadístico de los conjuntos.

	DATASET 1		DATASET 2		DATASET 3		DATASET 4	
	x	y	x	y	x	y	x	y
count	11.00	11.00	11.00	11.00	11.00	11.00	11.00	11.00
mean	9.00	7.51	9.00	7.50	9.00	7.50	9.00	7.50
std	3.32	2.02	3.32	2.03	3.32	2.03	3.32	2.03
min	4.00	4.26	4.00	3.10	4.00	5.39	8.00	5.25
25%	6.50	6.38	6.50	6.70	6.50	6.25	8.00	6.17
50%	9.00	7.58	9.00	8.14	9.00	7.11	8.00	7.04
75%	11.50	8.57	11.50	8.95	11.50	7.98	8.00	8.19
max	14.00	10.84	14.00	9.26	14.00	12.74	19.00	12.50

Si nos centramos en esta información, notamos que los estadísticos de las x de los cuatro conjuntos, principalmente la media y el desvío estándar, son prácticamente iguales (con diferencias menores a 0,01). Lo mismo sucede con los valores de y de los cuatro conjuntos.

Ahora, para terminar con el análisis, observemos las gráficas hechas sobre los cuatro conjuntos de datos.

Visualización del Cuarteto de Anscombe



A pesar de que los 4 conjuntos tienen la misma media, el mismo desvío estándar y la misma tendencia ascendente (los puntos se pueden describir como una recta con ecuación igual a $y = 0.5x + 3$ —esto lo veremos en detalle en las próximas clases—), queda claro que los cuatro conjuntos no son iguales; incluso todos son distintos con características particulares. Esto demuestra que las gráficas y la visualización de los datos resultan ser herramientas indispensables para el desarrollo del ciclo de análisis de datos.

1.2 ¿Qué es la visualización de datos?

La visualización de datos es la representación gráfica de información abstracta. Se

ocupa de mostrar información cuantitativa y cualitativa, de modo que el observador pueda ver patrones, tendencias o anomalías, constancias o variaciones, de formas que otros medios —como el texto o las tablas— no permiten. Los principales objetivos de la visualización son generar comprensión y comunicar.

1.3 ¿Por qué es importante la visualización de los datos?

La visualización se basa en el aprovechamiento del sistema visual humano como medio de comunicación. La vista es el sentido más importante y presenta características muy llamativas en la recepción de información. Una cantidad significativa del procesamiento de la información visual ocurre en paralelo a nivel preconscious y, posteriormente, alimentan procesos de nivel superior que implican el control consciente de la atención. Un ejemplo es la aparición repentina de objetos, como la aparición repentina de una figura roja en un mar de grises (un ejemplo de este efecto visual lo pueden ver en el [siguiente link](#)). No parece una habilidad asombrosa, pero en la prehistoria fue indispensable para detectar un depredador entre la vegetación. Aquí la relevancia de la percepción visual cobra sentido. Primero se observa la aparición de algún objeto (junto al reflejo de la atención y el susto), después se analiza qué objeto es y en qué circunstancia aparece (aquí está el razonamiento y el entendimiento de que el amigo que nos asustó no resulta ser una amenaza). Todo esto deviene de la evolución que valoró la vista como la principal herramienta para poder actuar en el mundo físico; y en la actualidad seguimos percibiendo las cualidades primitivas de la visión junto a la evolución de la percepción (para más material sobre esto, vea las [Leyes de Gestalt](#)).

¿Qué importancia tiene todo esto con los datos? Cualquiera puede leer números y datos crudos, pero es difícil llegar a un entendimiento más profundo. En cambio, una gráfica o un diagrama permite entrar por el lado subconsciente de la persona antes de que pueda analizar lo que ve. Así se puede aprovechar estos aspectos primitivos para poder dirigir la atención hacia lo más importante y entender con mayor facilidad lo que se quiere transmitir.

2. PRINCIPALES ELEMENTOS DE LA VISUALIZACIÓN

2.1 Marcas visuales

La visualización de datos requiere de componentes geométricos primitivos denominado marcas. Las marcas posibles son el punto, la línea y el área.

➔ Points



➔ Lines



➔ Areas




2.2 Elementos preatentivos

Los elementos preatentivos son propiedades de las marcas visuales que el cerebro procesa y detecta de forma inconsciente y rápida (en base a lo descrito en la sección anterior ¿Por qué es importante la visualización de los datos?).

2.2.1 Forma

- **Tamaño.** Representa fácilmente cualquier variable cuantitativa. No es recomendable para variables categóricas. Se puede aplicar cambiando cualquier dimensión de una marca, como el ancho, el largo, el espesor o el área.
- **Forma.** Se aplica solo a variables categóricas con pocos valores únicos.
- **Inclinación o curvatura.** Estos elementos son más extraños de encontrar, aunque también permiten representar principalmente variables cualitativas.



2.2.2 Color

- **Matiz.** Aplicable principalmente a variables categóricas. No se aconseja utilizarlo para marcar un orden o una magnitud. Aunque puede haber muchos colores posibles, se recomienda no utilizar más de siete.



- **Brillo.** Muy apropiado para variables ordinales, a partir del rango claro-oscuro.



- **Saturación.** Aunque es una propiedad posible de usar, se suele evitar su uso.



2.2.3 Posición

La posición sirve principalmente para representar variables cuantitativas continuas, discretas y ordinales. También se puede usar para visualizar categorías si agrupamos u ordenamos las marcas en distintas posiciones del plano. Cambiar levemente la ubicación de cada elemento en un plano puede cambiar completamente la interpretación de la gráfica. Por eso hay que prestar mucha atención a esta propiedad.




2.3 ¿Qué marca o elemento preatentivo usar?

La elección de las variables visuales para representar los atributos de los datos es muy importante. Representar un mismo atributo con diferentes variables puede cambiar totalmente la percepción, experiencia e interpretación de la información. Para eso tenemos dos principios claves a seguir:

- **Principio de expresividad.** La codificación visual debe mostrar la información más importante de los atributos de un dataset siguiendo los lineamientos previamente comentados.
- **Principio de efectividad.** Siempre se debe usar la variable visual más efectiva para la percepción. En la siguiente figura se ordena el nivel de efectividad de acuerdo a cada elemento preatentivo.

➔ Magnitude Channels: Ordered Attributes



➔ Identity Channels: Categorical Attributes

